Unidad III - MODELOS DE REGRESIÓN

Msc. Lic. Víctor Rodríguez Estévez

12 de octubre de 2026



El Problema

Estimación

- Tengo conocimiento del área de mi casa
- Tengo conocimiento del número de habitaciones
- Tengo conocimiento de su antigüedad.
- Tengo conocimiento de....su ubicación, materiales, tamaño de construcción, etc...

¿En cuanto puedo vender mi casa?



El Problema

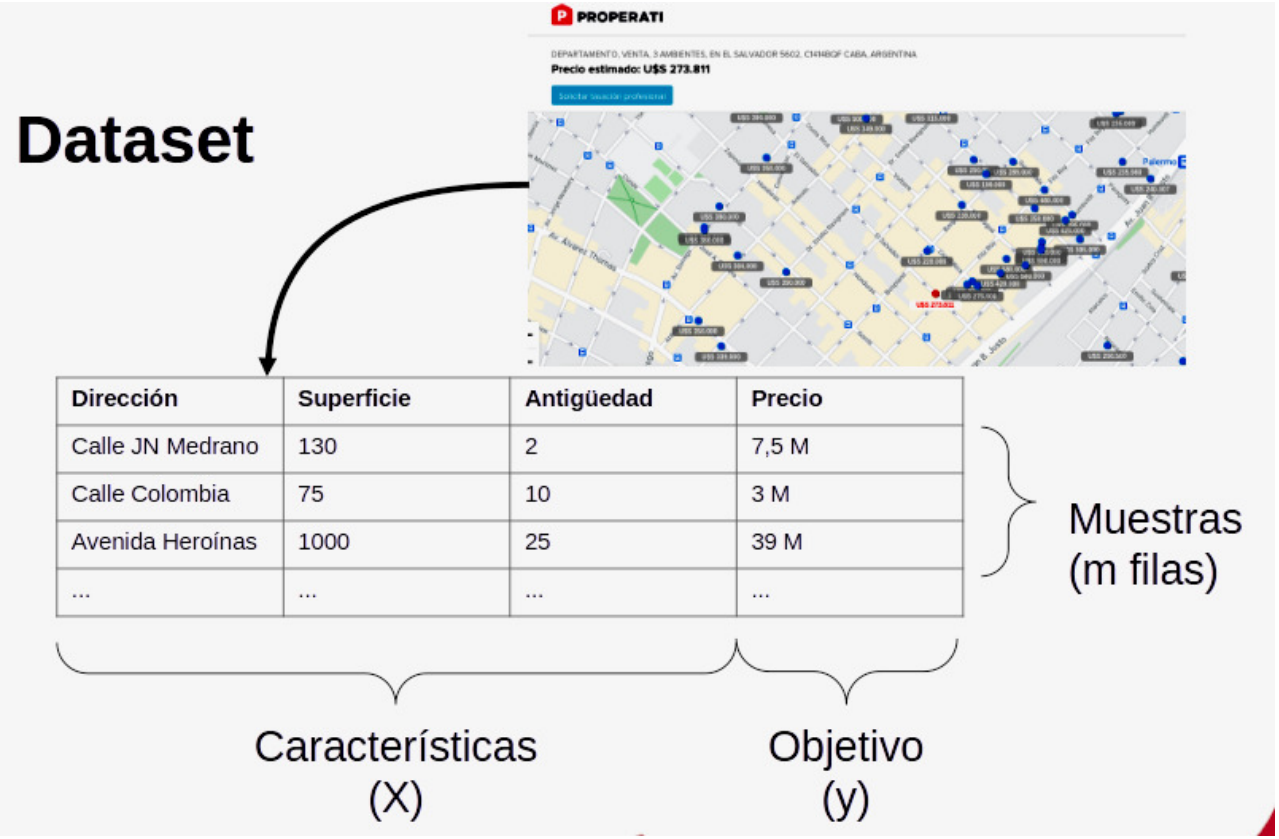
Estimación

- Además ... puedo acceder a registros de compras de casas.
- Con ello tendré los precios en los que se vendieron determinadas casas con determinadas características.
- **Tarea**: predecir el precio de mi casa, **Experiencia**: registros de compras de casas, **Medida de rendimiento:** .....

¿En cuanto puedo vender mi casa?



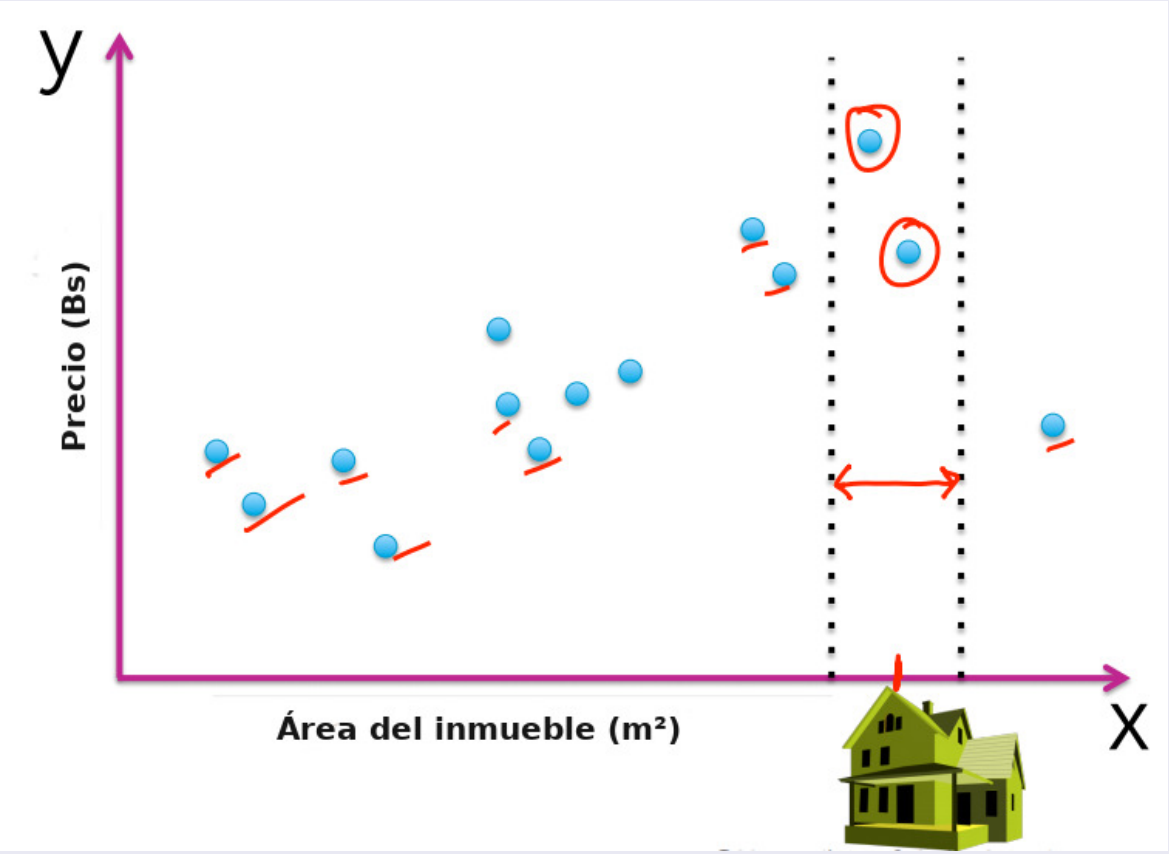
El problema



- X: **Variables característica (Tamaño del Área del inmueble)**
- y: **Variable Objetivo (Precio)**
- Notar que y, es de naturaleza **continua**.

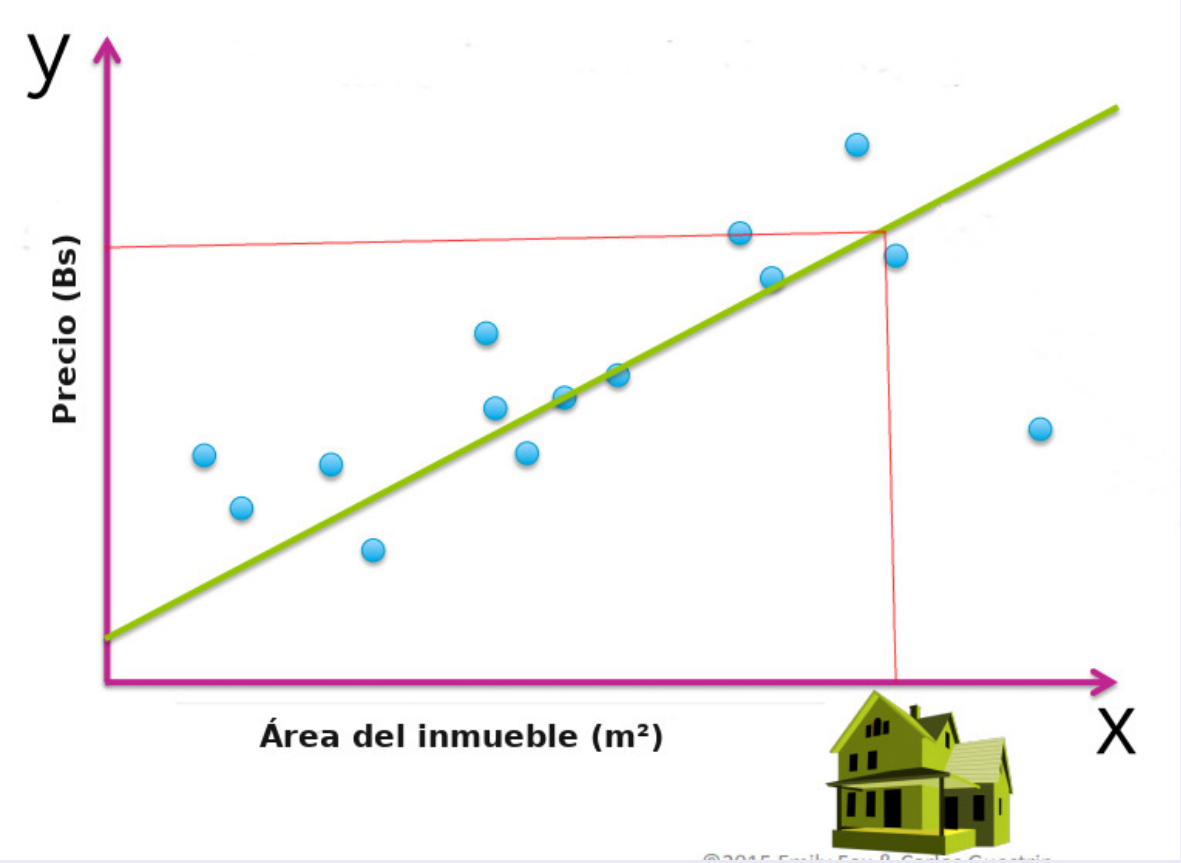
El Problema

Predicción



- Mi casa tiene estas **características**!!!
- Puedo **fijarme en este rango de precios**, **características similares (experiencia)**.

El Modelo



- El modelo $h(x) = \theta_0 + \theta_1 x$

El Problema

Conjunto entrenamiento

```
In [2]:  1 datos = pandas.read_csv("datos.csv")
         2 datos
```

Out[2]:

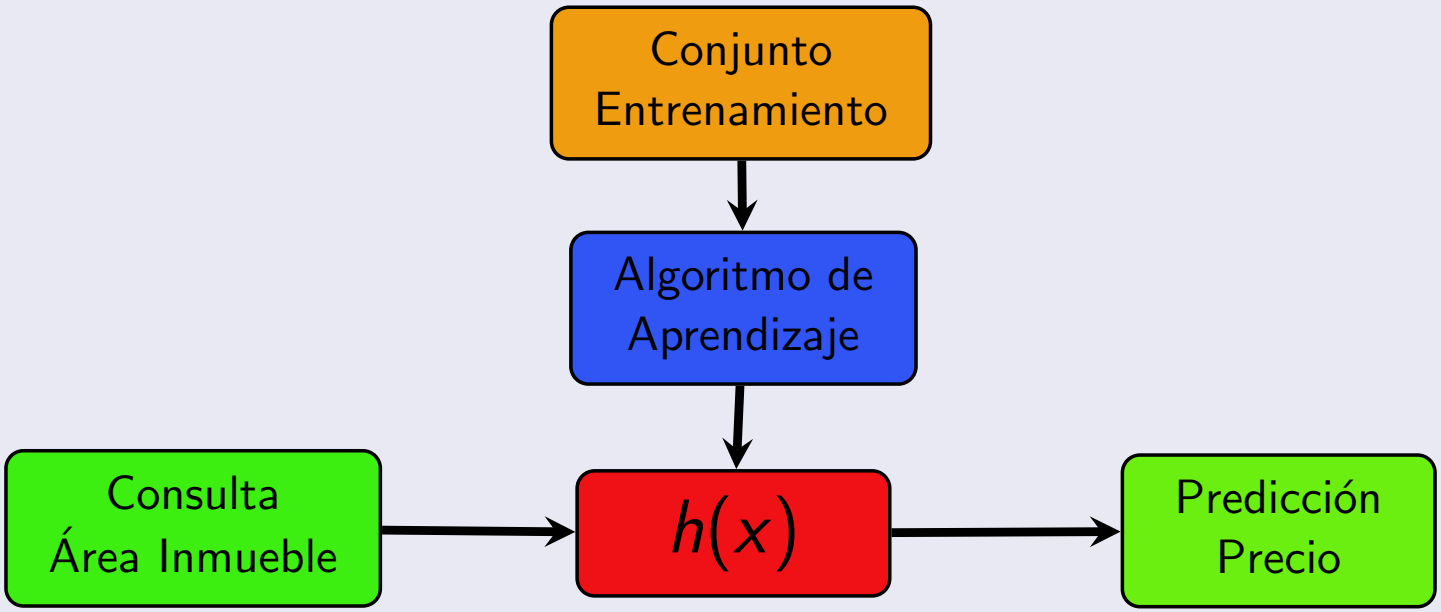
	Area	Precio
0	2104	460
1	1416	232
2	1534	315
3	852	178

Notación

- m: Tamaño del conjunto entrenamiento (número de filas)
- $X^{(i)}$ iesimo valor de la matriz X, ejemplo $X^{(2)} = 1534$
- $y^{(i)}$ iesimo valor del vector y, ejemplo $y^{(2)} = 315$
- $(X^{(1)}, y^{(1)}) = (1416, 232)$

El Problema

El Modelo



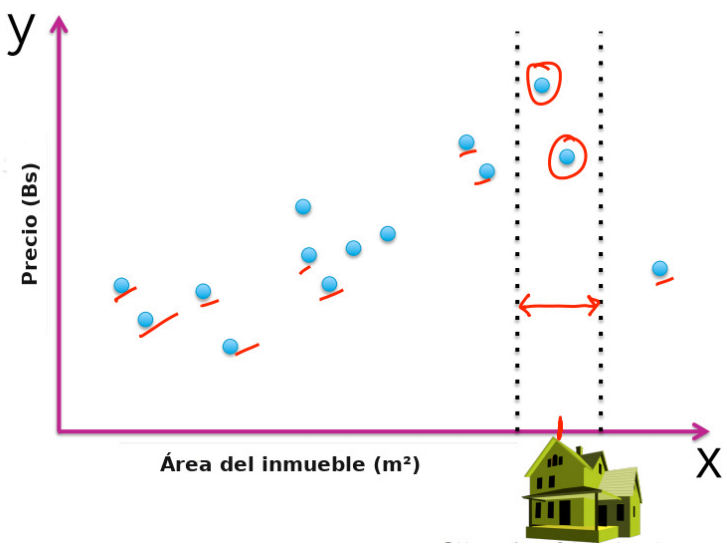
- **Entrada**: Consulta con el área del inmueble
- **Proceso**: Algoritmo de aprendizaje entrenado
- **Salida**: Predicción del precio de la vivienda
- **Función** $h(x)$: Hipótesis que mapea área $\rightarrow$ precio

El Problema de la Regresión

Problema

- **Objetivo:** Predecir el valor de una o más variables objetivo continuas $h(x)$) dado un vector de entrada $\mathbf{x}$ de n dimensiones.
- **Nuestro ejemplo:** Predecir el precio de una casa basado en su tamaño.
- **Aprendizaje Supervisado:** Tenemos la "respuesta correcta" para cada ejemplo.
- **Problema de Regresión:** Predecir una salida de valor continuo.
- **Enfoque Probabilístico:** Modelar la distribución predictiva $p(h(x)|\mathbf{x})$ para expresar la incertidumbre.
- **Pérdida Cuadrática:** La predicción óptima es la expectativa condicional $\mathbb{J}(\theta)[h(x)|\mathbf{x}]$.

Representación del Modelo



El Modelo

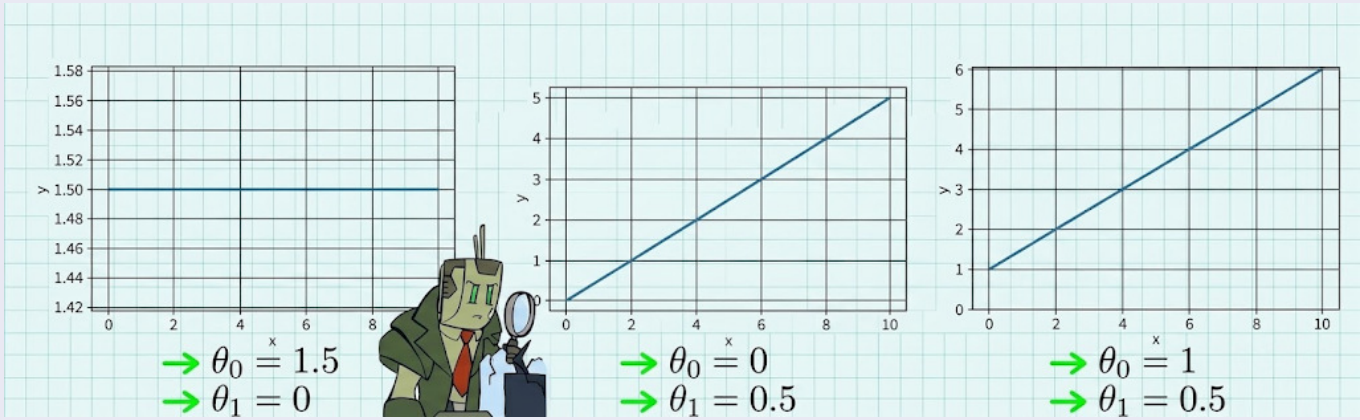
- Modelo de regresión lineal con una variable
- **Hipótesis:**

$$h_\theta(x) = \theta_0 + \theta_1 x$$

  - θ_0: Sesgo(bias)
  - θ_1: Pendiente
  - x: Variable de entrada (ej. tamaño de casa)

Parámetros del Modelo

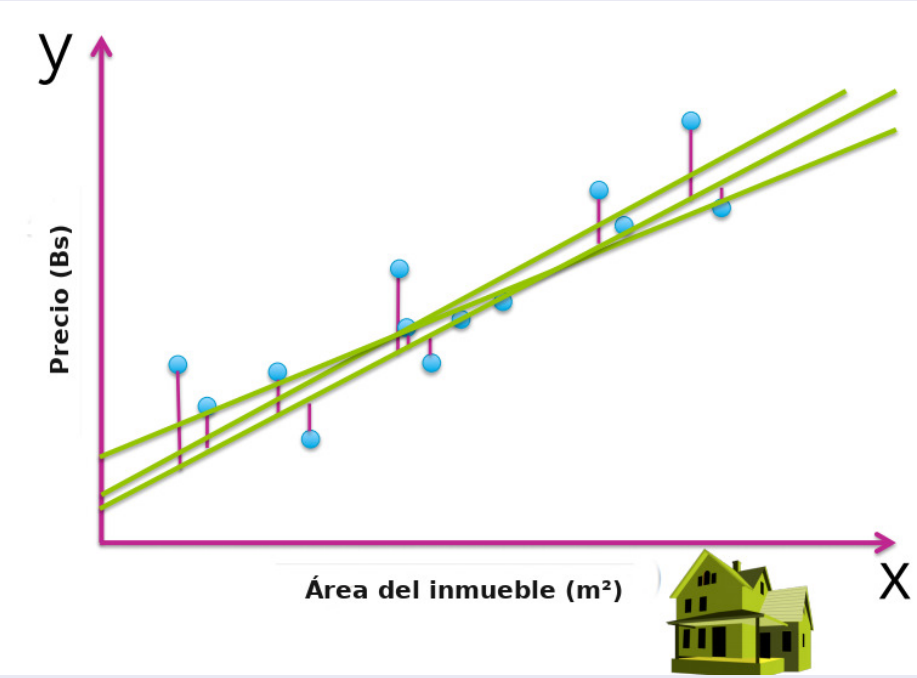
Que hace que el modelo sea diferente?



Como elegimos los mejores θs?

Parámetros del Modelo

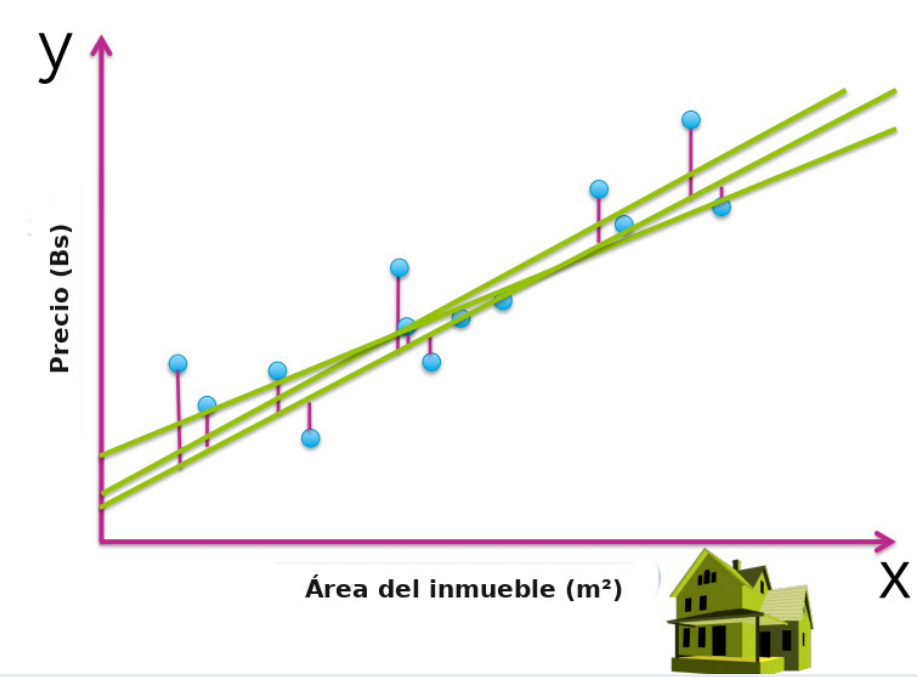
Que hace que el modelo sea diferente?



- **Error:** Lo que el modelo $h_{(x)}$ indica menos lo que en realidad es y!!!!

Parámetros del Modelo

Que hace que el modelo sea diferente?



- **Función Error:** $J_{(\theta_0,\theta_1)} = \frac{1}{2m}\sum_{i=0}^{m}(h_{(x^{(i)})} - y^{(i)})^2$
- **Función Error:** $J_{(\theta_0,\theta_1)} = \frac{1}{2m}\sum_{i=0}^{m}(\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2$

Función objetivo

Intuitivo: Función Error

Sea $\theta_0 = 0$

- **El modelo:** $h(x) = \theta_0 + \theta_1 x$
- **Parámetros:** $[\theta_0, \theta_1]$
- **Función error:**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2$$

- **Objetivo:** Minimizar $J(\theta_0, \theta_1)$

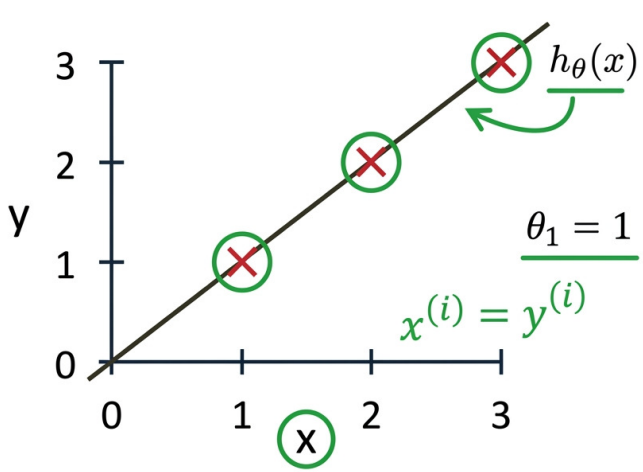
- **El modelo:** $h(x) = \theta_1 x$
- **Parámetros:** $[\theta_1]$
- **Función error:**

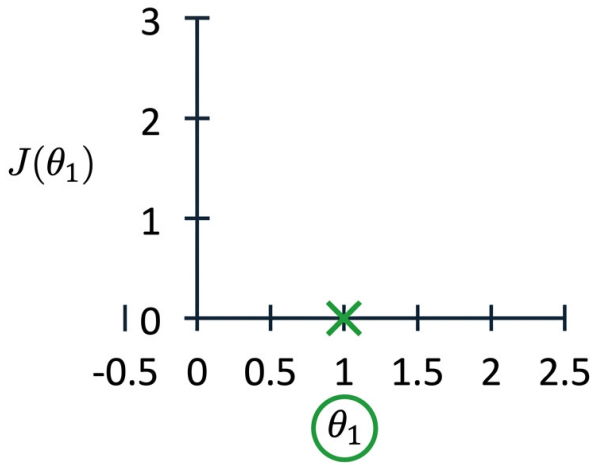
$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(\theta_1(x^{(i)}) - y^{(i)} \right)^2$$

- **Objetivo:** Minimizar $J(\theta_1)$

El Problema

Hagamos una simplificación, sea $\theta = 0$

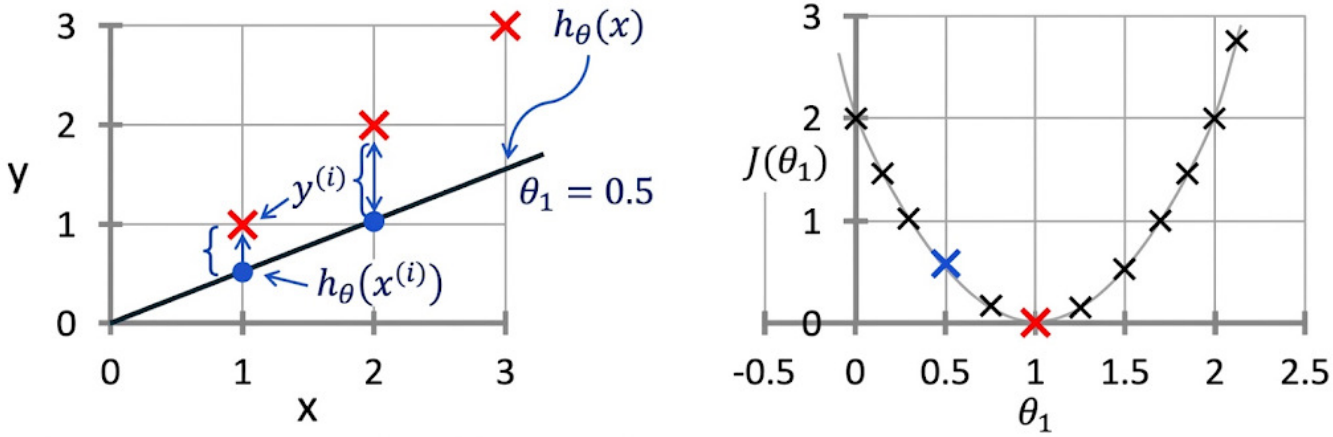




Relación $h(x)$ - $J(\theta_0, \theta_1)$

- Sea el conjunto entrenamiento $(x, y) = [(1, 1), (2, 2), (3, 3)]$
- Sea $\theta_0 = 0$, $\theta_1 = 1$
- Entonces $h(x) = x$
- $J_{(\theta_0,\theta_1)} = \frac{1}{2*3}[(1-1)^2 + (2-2)^2 + (3-3)^2$
- $J_{(\theta_0,\theta_1)} = 0$

El Problema



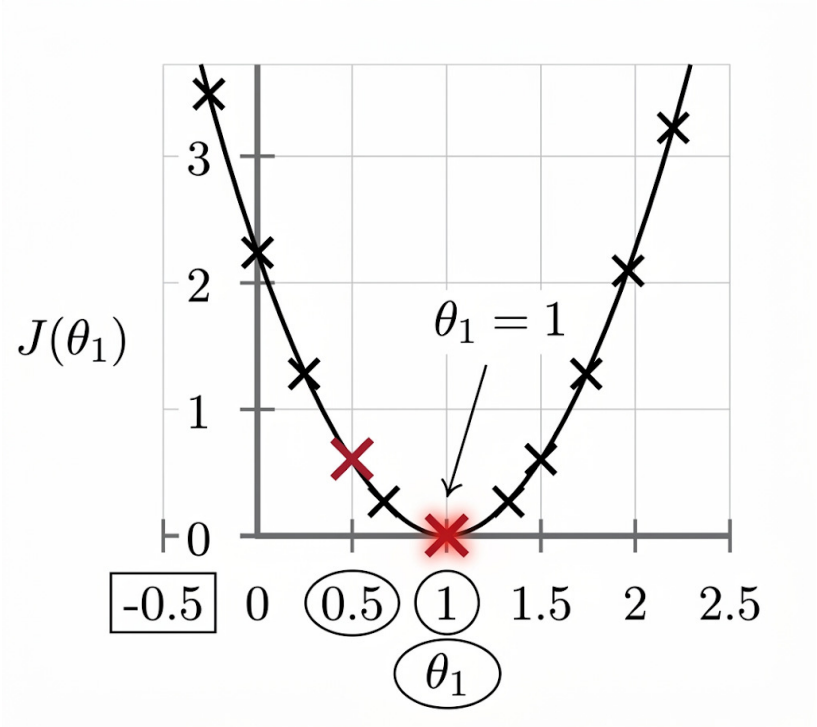
Relación $h(x)$ - $J(\theta_0, \theta_1)$

- Sea el conjunto entrenamiento $(x, y) = [(1, 1), (2, 2), (3, 3)]$
- Sea $\theta_0 = 0$, $\theta_1 = 0{,}5$
- Entonces $h(x) = 0{,}5x$
- $J_{(\theta_0,\theta_1)} = \frac{1}{2*3}[(0{,}5 - 1)^2 + (1 - 2)^2 + (1{,}5 - 3)^2$
- $J_{(\theta_0,\theta_1)} = 0{,}5833$

Función costo:

- Cual sería el valor y la gráfica para $\theta_1 = 1{,}5????$ para $\theta_1 = 0{,}5????$
- Comprueba el valor de $J(\theta)$ cual tiene el menor error?
- Grafica el modelo con esos parámetros.
- Cual ajusta mejor?

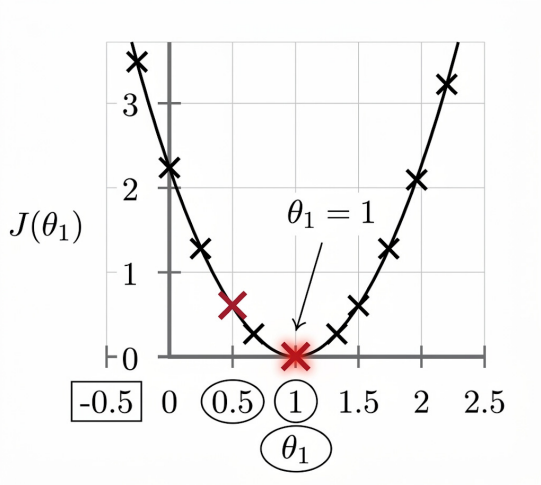
El Problema



Relación $h(x)$ - $J(\theta_0, \theta_1)$

- Básicamente $J(\theta_1)$ es una **parábola**
- El valor de $J(\theta_1)$ mínimo, resulta ser el que mejor **ajusta a los datos del conjunto entrenamiento!!!!**
- Recuerdas como encontrar ese punto???

El Problema

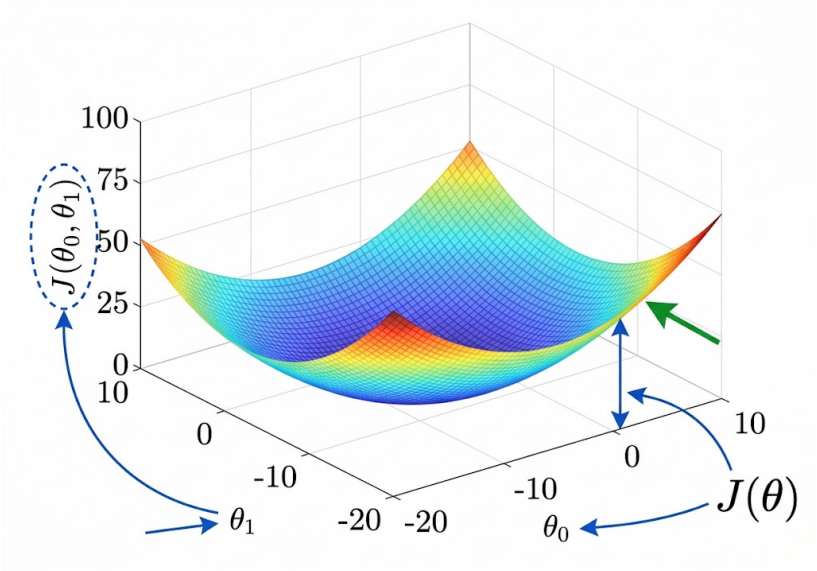


Efectivamente... la derivada..

Relación $h(x)$ - $J(\theta_0, \theta_1)$

- $\frac{d}{d\theta_1} J_{(\theta_1)} = 0$
- $\frac{d}{d\theta_1} J_{(\theta_1)} = \frac{1}{2m} \sum_{i=0}^{m} (\theta_1 x^{(i)} - y^{(i)})^2 = 0$
- $\frac{1}{m} \sum_{i=0}^{m} (\theta_1 x^{(i)} - y^{(i)}) x^{(i)} = 0$
- Encontramos el punto de inflexión!!!!

El Problema



Relación $h(x)$ - $J(\theta_0, \theta_1)$

- $\nabla_\theta J_{(\theta_0,\theta_1)} = 0$
- $[\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}] = 0$
- $[\frac{1}{m}\sum_{i=0}^{m}(\theta_1 x^{(i)} - y^{(i)}), \frac{1}{m}\sum_{i=0}^{m}(\theta_1 x^{(i)} - y^{(i)})x^{(i)}] = [0, 0]$

Función costo:

- Implementar la función costo $j_{(\theta_0,\theta_1)}$
- Graficar la función $j_{(\theta_0,\theta_1)}$, en 3D, $\theta_0, \theta_1, j_{(\theta_0,\theta_1)}$
- Graficar la función $j_{(\theta_0,\theta_1)}$, como curvas de nivel, θ_0, θ_1
- Seleccionar dos parámetros (θ_0, θ_1) mostrarlos en las graficas anteriores.
- Con los parámetros anteriores, graficar el modelo $h(x)$ junto con los datos del conjunto entrenamiento.
- Podemos intuir los parámetros óptimos según la gráfica? Como ajusta este modelo a los datos del conjunto entrenamiento?

Función objetivo

Mínimo Global

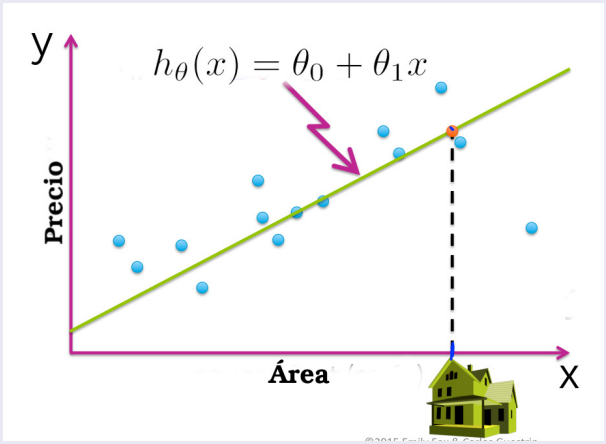


Figura: Gráfica del modelo

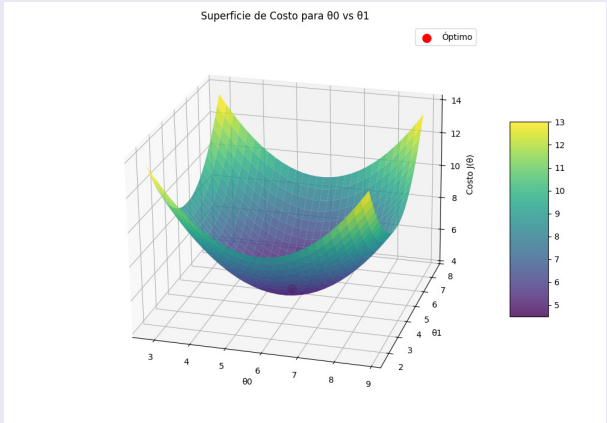


Figura: Gráfica del error

Función objetivo

Mínimo Global

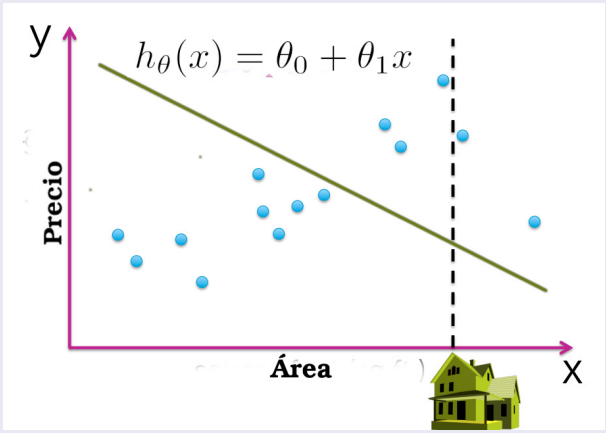


Figura: Gráfica del modelo

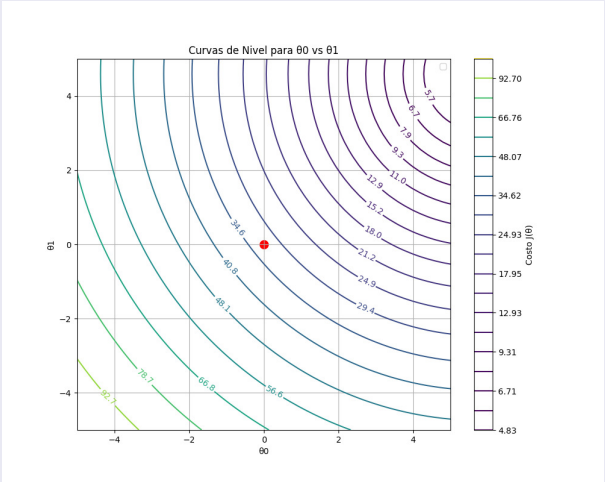


Figura: Gráfica del error

Regresión Multi Variable

Área (m^2)	Número de Habitaciones	Numero de pisos	Anntiguedad (precioss)	Precio
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

Figura: Más características

- n: número de características
- $x^{(i)}$: i ésima fila de características
- $x_j^{(i)}$: i ésimo valor de la característica j

Regresión Multi Variable

Notación vectorial

- $h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 ... \theta_n x_n$
- $h(x) = \theta_0 + \sum_{j=1}^{n} \theta_j X_j$
- $h(x) = \sum_{j=0}^{n} \theta_j X_j$, con $X_0 = 1$ *(Unidad de sesgo)*
- $\boxed{h(x) = \Theta^T X \textbf{, con } X_0 = 1}$

Resumen - El Modelo

- **Modelo de predicción que calcula una suma ponderada de características**
- **Ecuación de predicción**:

$$h(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

- **Forma vectorizada**:

$$h(x) = \theta^T \cdot \mathbf{x}$$

- θ_0: término de sesgo (bias)
- θ_1 a θ_n: pesos de las características

Función de Error (MSE)

Resumen - Función Error

- Se utiliza el Error Cuadrático Medio ($J(\theta)$) para medir el rendimiento
- **Función de error**:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(\theta^T \cdot \mathbf{x} - y \right)^2$$

- **Objetivo**: encontrar θ que minimice $J(\theta)$
- m: número de instancias de entrenamiento

Entendiendo el modelo

Máxima Verosimilitud y Mínimos Cuadrados

- **Suposición**: La variable objetivo 'y' está dado por una función determinista ($h(x)$) más ruido gaussiano

$$y = h(\mathbf{x}) + \epsilon$$

- Donde $\epsilon \sim \mathcal{N}(0, \beta^{-1})$, $\mu = 0$(en promedio, el ruido es cero), β se conoce como precisión (es el inverso de la varianza, $\beta = \frac{1}{\sigma^2}$). Un β alto (varianza baja) significa que los datos están muy cerca de la función $h(x)$. Un β bajo (varianza alta) significa que los datos están muy dispersos.

Entendiendo el modelo

Modelo Probabilístico

- Distribución condicional:

$$p(y|\mathbf{x}, \theta, \beta) = \mathcal{N}(y|h(\mathbf{x}), \beta^{-1})$$

- La **predicción óptima** (con pérdida cuadrática) es la **esperanza condicional**:

$$\mathbb{E}[y|\mathbf{x}] = h(\mathbf{x})$$

- Básicamente una **distribución normal**, donde **la esperanza es igual a la media**.
- Por lo tanto, **predecimos** $h(x)$ que es exactamente **la media de la distribución**

Función Error: Función de Verosimilitud

- **Para un conjunto de datos $\{\mathbf{x}_m, y_m\}$ con $m = 1, \ldots,$:**

$$p(\mathbf{y}|\mathbf{X}, \theta, \beta) = \prod_{i=1}^{m} \mathcal{N}(y_i|\theta^T \mathbf{x}_i, \beta^{-1})$$

- **Log-verosimilitud:**

$$\ln p(\mathbf{y}|\theta, \beta) = \underbrace{\frac{N}{2}\ln\beta - \frac{N}{2}\ln(2\pi)}_{\text{Términos constantes (sesgo)}} \underbrace{-\beta\left[\frac{1}{2}\sum_{n=1}^{N}(y_i - \theta^T \mathbf{x}_i)^2\right]}_{J(\theta)\text{(varianza)}}$$

- **Donde la función de error de suma de cuadrados es:**

$$J(\theta) = \frac{1}{2}\sum_{i=1}^{m}\{y - \theta^T \mathbf{x}_i\}^2$$

Solución de Máxima Verosimilitud

- **Maximizar la verosimilitud equivale a minimizar $J(\theta)$**
- **El gradiente de la log-verosimilitud:**

$$\nabla \ln p(\mathbf{y}|\theta, \beta) = \sum_{i=1}^{m} \{y_n - \theta^T \mathbf{x}_i\} \mathbf{x}_i^T$$

- Igualando a cero obtenemos la **ecuaciones normal**:

$$\theta = (\boldsymbol{X}^T \boldsymbol{X})^{-1} \boldsymbol{X}^T \mathbf{y}$$

- Donde $\boldsymbol{X}$ es la **matriz de diseño**:

$$\boldsymbol{X} = \begin{pmatrix} x_0^{(1)} & \cdots & x_n^{(1)}) \\ \vdots & \ddots & \vdots \\ x_0^{(m)} & \cdots & x_n^{(m)} \end{pmatrix}$$

Ecuación Normal

Resolución

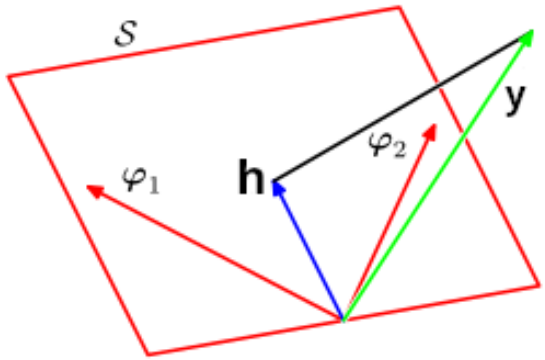
- **Solución cerrada para encontrar θ óptimo**
- Ecuación:

$$\hat{\theta} = \left(X^T \cdot X\right)^{-1} \cdot X^T \cdot y$$

- **Ventajas:**
  - **Solución exacta** en un solo paso
  - Eficiente para **datasets pequeños**
- **Desventajas:**
  - Complejidad computacional $O(n^{2,4})$ a $O(n^3)$
  - **Lento con muchas características**

Interpretación Geométrica

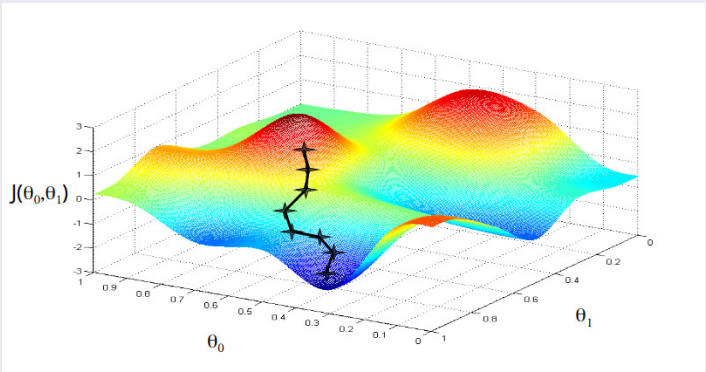
- Consideramos un espacio N-dimensional donde cada eje corresponde a y_n, tal que $y = (y_1, ..., y_n)^T$ es un vector en este espacio.
- Cada función base $\phi_j(\mathbf{x}_n)$ forma un vector φ_j en este espacio
- La **solución de mínimos cuadrados** corresponde a la **proyección ortogonal** del vector **h** sobre el subespacio generado por ϕ
- La predicción $\mathbf{h} = \theta \boldsymbol{X}$ **es esta proyección**
- $J(\theta)$ es entonces igual (hasta un factor de $\frac{1}{2}$) a la **distancia euclidiana al cuadrado entre** $h(x)$ **y** y.



Función objetivo

Buscar parámetros óptimos

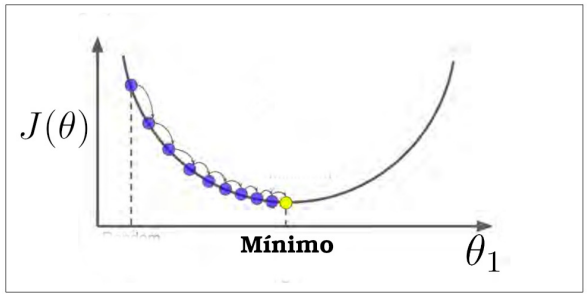
Resolución por algoritmo de optimización



- El **Descenso de Gradiente** es un algoritmo de **optimización**.
- **Ajustar los parámetros** iterativamente para **minimizar una función** $J(\theta)$
- Mide el **gradiente** local $\nabla_\theta J(\theta)$ y va en la dirección del gradiente descendente.

Descenso de Gradiente

Algoritmo para minimizar $J(\theta_0, \theta_1)$:



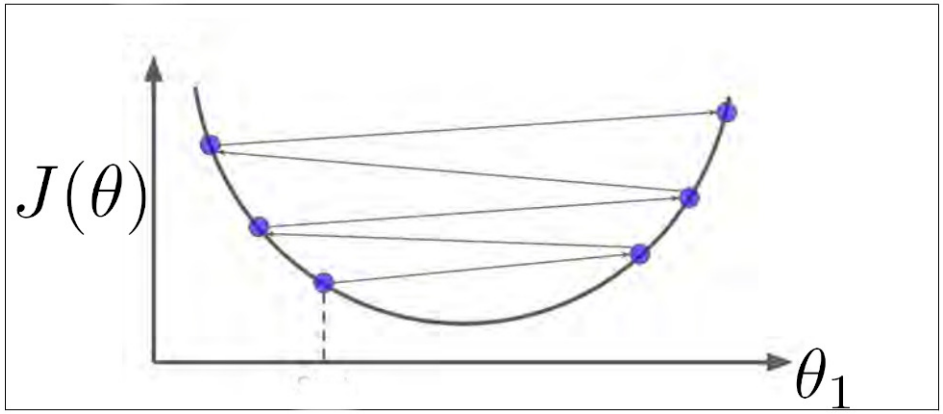
$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Actualizar parámetros

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

Consideraciones Clave



Tasa de Aprendizaje

- **Tasa de aprendizaje (α)**:
  - Demasiado pequeña: Convergencia lenta
  - Demasiado grande: Puede divergir
- **Descenso de gradiente ingenuo:**
  - Usa todos los ejemplos en cada iteración
- **Convergencia**:
  - Automáticamente toma pasos más pequeños al acercarse al mínimo

Descenso de Gradiente

Para (n=1):

Repetir{

$$\theta_0 := \theta_0 - \alpha \underbrace{\frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})}_{\frac{\partial}{\partial \theta_0} J(\theta)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x^{(i)}$$

(simultáneamente actualizamos θ_0, θ_1)

}

Para : $(n \geq 1)$

Repetir{

$$\theta_j := \theta_j - \alpha \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x_j^{(i)}$$

(Simultáneamente actualizamos θ_j para $j = 0, \ldots, n$)

}

$$\theta_0 := \theta_0 - \alpha \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x_1^{(i)}$$

$$\theta_2 := \theta_2 - \alpha \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x_2^{(i)}$$

Figura: Más características

Descenso de Gradiente

- **Algoritmo iterativo para minimizar la función de costo $J(\theta)$**
- **Actualización de parámetros:**

$$\theta = \theta - \alpha \nabla_\theta J(\theta)$$

- α: tasa de aprendizaje
- $\nabla_\theta J(\theta)$: vector gradiente

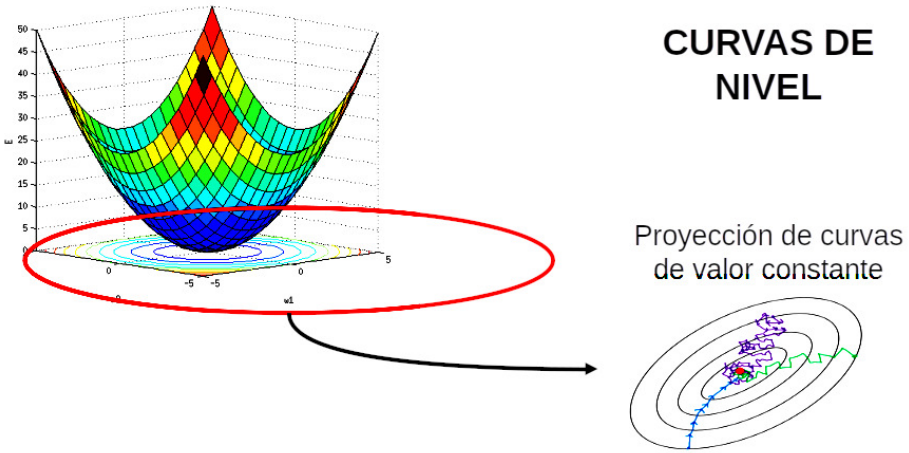
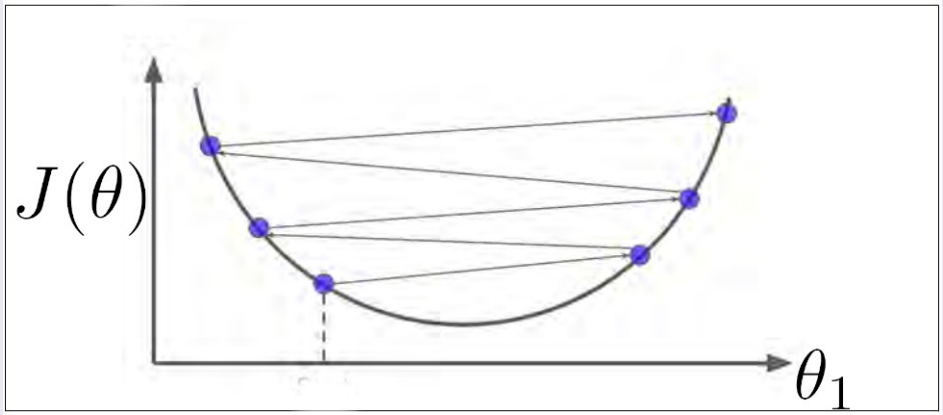


Figura: Ilustración del Descenso de Gradiente

Tasa de Aprendizaje

Learning Rate

- Parámetro **crítico para la convergencia**
- **Demasiado pequeña**: convergencia lenta
- **Demasiado grande: puede divergir**
- Debe ajustarse cuidadosamente



Descenso de Gradiente Estocástico

Problema del Descenso de Gradiente

- Utiliza **todo el conjunto de entrenamiento** para calcular los gradientes en cada paso
- Para conjuntos de datos grandes:
  - Cálculo del gradiente es **lento**
  - Requiere mucha **memoria**
  - Cada iteración es **costosa computacionalmente**
- Fórmula de actualización:

$$\theta = \theta - \alpha \cdot \nabla_\theta J(\theta)$$

donde $J(\theta)$ es el costo sobre **todos** los datos

Limitaciones

- Para **conjuntos de datos grandes**, el procesamiento **puede ser costoso**
- **Solución**: **Descenso de gradiente estocástico**
- Actualización después de cada patrón:

$$\theta^{(\tau+1)} = \theta^{(\tau)} - \alpha \nabla J(\theta)$$

- Para el error de suma de cuadrados:

$$\theta^{(\tau+1)} = \theta^{(\tau)} + \alpha(y_i - \theta^{(\tau)T} \boldsymbol{X}_i)\boldsymbol{X}_i$$

- Conocido como algoritmo **LMS** (Least-Mean-Squares)

¿Qué es el SGD?

Definición

El Descenso de Gradiente Estocástico (SGD) selecciona **una instancia aleatoria** del conjunto de entrenamiento en cada paso y calcula el gradiente basado únicamente en esa instancia.

- Mucho más **rápido** que Batch GD
- Permite entrenar con **grandes conjuntos** de datos
- Puede implementarse como **algoritmo en línea** (online)
- Fórmula de actualización:

$$\theta = \theta - \alpha \cdot \nabla_\theta J(\theta, x^{(i)}, y^{(i)})$$

donde $(x^{(i)}, y^{(i)})$ es una sola instancia aleatoria

Descenso de Gradiente Estocástico

Ventajas del SGD

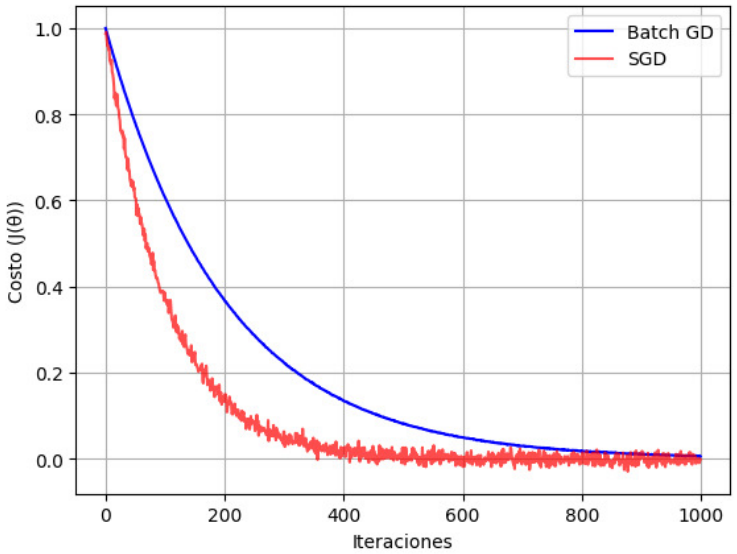
- **Eficiencia computacional**:
  - Menos cálculos por iteración
  - Menor uso de memoria
- **Escalabilidad**:
  - Maneja conjuntos de datos masivos
  - Útil para aprendizaje en línea
- **Evita mínimos locales**:
  - La naturaleza estocástica ayuda a escapar de mínimos locales
- **Convergencia más rápida**:
  - En problemas grandes, alcanza solución razonable rápidamente

Descenso de Gradiente Estocástico

Desventajas del SGD

- **Comportamiento errático**:
  - La función de costo fluctúa en lugar de disminuir suavemente
  - Disminuye solo en promedio a largo plazo
- **No converge exactamente al mínimo**:
  - Oscila alrededor del mínimo
  - Valores finales son buenos pero no óptimos
- **Sensibilidad a la tasa de aprendizaje**:
  - Requiere ajuste cuidadoso del learning rate

Visualización del Comportamiento del SGD



- **Batch GD**: Convergencia suave pero lenta
- **SGD**: Camino más ruidoso pero más rápido

Descenso de Gradiente

Variantes del SGD

- **Minibatch Gradient Descent**:
  - Compromiso entre Batch GD y SGD
  - Usa pequeños lotes de datos (ej. 32-512 instancias)
- **SGD con Momentum**:
  - Acumula velocidad en direcciones persistentes
  - Reduce oscilaciones
- **Learning Rate Adaptativo**:
  - AdaGrad, RMSprop, Adam
  - Ajustan automáticamente la tasa de aprendizaje

Consejos Prácticos para Usar SGD

- **Escalonamiento del Learning Rate**:
  - Comenzar con tasa alta, reducirla gradualmente
- **Mezcla de datos**:
  - Barajar los datos antes de cada época
  - Evitar ciclos en el orden de los datos
- **Normalización**:
  - Diferentes escalas en las variables características ocasionan problemas en el algoritmo
  - Normalizar los datos: $X = \frac{x-\mu}{\sigma}$

Algoritmo SGD con Limites para Regresión Lineal

Entrada: Conjunto de entrenamiento (X, y), tasa de aprendizaje α, épocas máximas T, tamaño de lote k

Salida: Parámetros óptimos θ

Inicializar θ aleatoriamente (ej. $\theta = \mathbf{0}$);

para *época* $= 1$ **a** T **hacer**

  Mezclar datos aleatoriamente;

  para *cada lote de k ejemplos* (X_b, y_b) **hacer**

    Calcular error: $\epsilon_b = X_b\theta - y_b$;

    Gradiente: $\nabla_\theta = \frac{1}{k} X_b^T \epsilon_b$;

    Actualizar: $\theta \leftarrow \theta - \alpha \nabla_\theta$;

  fin

  si $\|\nabla_\theta\|_2 <$ *tol* **entonces**

    break (parada temprana);

  fin

fin

devolver θ;

Algoritmo 1: Descenso de Gradiente Estocástico

Introducción a las métricas

Evaluación del Modelo

- En problemas de regresión, **necesitamos métricas** para evaluar el **rendimiento de nuestros modelos**
- La regresión lineal modela la relación entre variables independientes (X) y una dependiente (y)
- Las métricas nos ayudan a:
  - Comparar diferentes modelos
  - Seleccionar el mejor modelo
  - Diagnosticar problemas

Tipos de Métricas Principales

Métricas Comunes

- Error Cuadrático Medio (MSE)
- Raíz del Error Cuadrático Medio (RMSE)
- Error Absoluto Medio (MAE)
- Coeficiente de Determinación (R^2)
- Error Absoluto Porcentual Medio (MAPE)

Error Cuadrático Medio (MSE)

Mean Squared Error

$$MSE = \frac{1}{m}\sum_{i=1}^{m}(h(x^{(i)}) - y^{(i)})^2 \tag{1}$$

- Promedia los cuadrados de las diferencias entre valores reales (y^i) y predichos ($h(x^i)$)
- Penaliza más los errores grandes (por el cuadrado)
- Sensible a outliers
- Unidades al cuadrado de la variable objetivo

Ejemplo

Si $y = [3, -0{,}5, 2, 7]$, $h(x) = [2{,}5, 0{,}0, 2, 8]$

$MSE = \frac{1}{4}[(3 - 2{,}5)^2 + (-0{,}5 - 0)^2 + (2 - 2)^2 + (7 - 8)^2] = 0{,}375$

Raíz del Error Cuadrático Medio (RMSE)

Root Mean Squared Error

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(h(x^{(i)}) - y^{(i)})^2} \tag{2}$$

- Raíz cuadrada del MSE
- Misma unidad que la variable objetivo
- También sensible a outliers
- Interpretación más intuitiva que MSE

Ejemplo (continuación)

$RMSE = \sqrt{0{,}375} \approx 0{,}612$

Error Absoluto Medio (MAE)

Mean Absolute Error

$$MAE = \frac{1}{m}\sum_{i=1}^{m}|h(x^i) - y^{(i)}| \tag{3}$$

- Promedia las diferencias absolutas
- Menos sensible a outliers que MSE/RMSE
- Misma unidad que la variable objetivo
- No penaliza tanto los errores grandes

Ejemplo (continuación)

$MAE = \frac{1}{4}[|3 - 2{,}5| + |-0{,}5 - 0| + |2 - 2| + |7 - 8|] = 0{,}5$

Coeficiente de Determinación (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^{m}(h(x^{(i)}) - y^{(i)})^2}{\sum_{i=1}^{m}(y^{(i)} - \bar{y})^2} \tag{4}$$

- Mide la proporción de varianza explicada por el modelo
- $\bar{y}$ es la media de los valores reales
- Rango: $(-\infty, 1]$ (puede ser negativo para modelos muy malos)
- 1 = ajuste perfecto, 0 = modelo no es mejor que usar la media

Ejemplo (continuación)

$\bar{y} = 2{,}875$

$R^2 = 1 - \frac{1{,}5}{(3-2{,}875)^2+(-0{,}5-2{,}875)^2+(2-2{,}875)^2+(7-2{,}875)^2} \approx 0{,}95$

Error Absoluto Porcentual Medio (MAPE)

Mean Absolute Percentage Error

$$MAPE = \frac{100\,\%}{m} \sum_{i=1}^{m} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \tag{5}$$

- Expresa el error como porcentaje
- Útil para comparar entre diferentes escalas
- Problemas cuando $y_i = 0$
- Asimetría: penaliza más las subestimaciones

Ejemplo (continuación)

$$MAPE = \frac{100\,\%}{4} \left(\left| \frac{3-2{,}5}{3} \right| + \left| \frac{-0{,}5-0}{-0{,}5} \right| + \left| \frac{2-2}{2} \right| + \left| \frac{7-8}{7} \right| \right) \approx 45{,}24\,\%$$

Comparación de Métricas

Cuadro: Resumen de Métricas para Nuestro Ejemplo

Métrica	**Valor**
MSE	0.375
RMSE	0.612
MAE	0.5
R^2	0.95
MAPE	45.24 %

- R^2 alto indica buen ajuste en general
- MAPE alto sugiere cuidado con errores porcentuales
- Diferentes métricas dan diferentes perspectivas

¿Cuándo Usar Cada Métrica?

- **MSE/RMSE**: Cuando los errores grandes son particularmente indeseables
- **MAE**: Cuando todos los errores deben tratarse por igual
- **R^2**: Para comparar modelos o explicar el rendimiento a stakeholders
- **MAPE**: Cuando se necesita interpretación en términos porcentuales

Consideraciones

- Ninguna métrica es perfecta para todos los casos
- Es recomendable mirar varias métricas juntas
- Considerar el contexto del problema

¿Por qué necesitamos validación cruzada?

- **Problema**: Evaluar modelos con el mismo conjunto de entrenamiento lleva a:
  - Sobreajuste (overfitting)
  - Estimaciones optimistas del rendimiento
  - Falta de generalización
- **Solución**: Validación cruzada
  - Uso más eficiente de datos
  - Estimación más realista del rendimiento
  - Detección de sobreajuste

Objetivos clave

- Evaluar capacidad de generalización
- Comparar modelos objetivamente
- Seleccionar hiperparámetros

¿Qué es la Validación Cruzada?

Definición formal

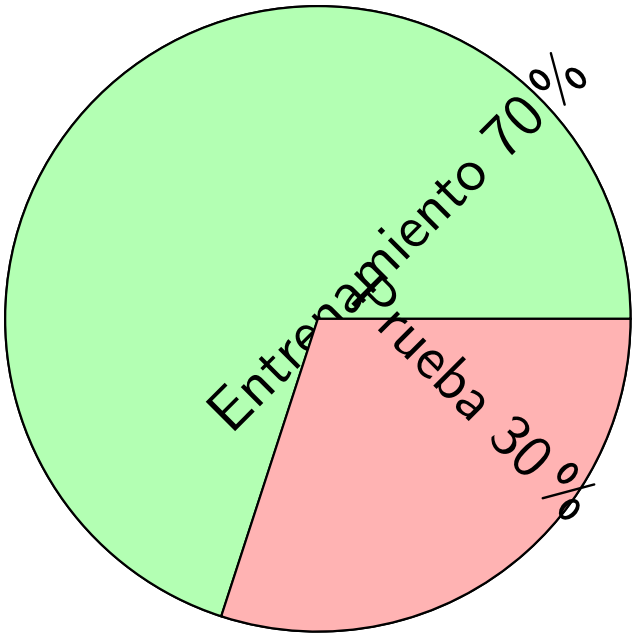
Técnica para evaluar la capacidad de generalización de un modelo dividiendo repetidamente los datos en conjuntos de entrenamiento y prueba.

- **Ventajas**:
  - Usa todos los datos para entrenar y validar
  - Reduce varianza en la estimación
  - Detecta sobreajuste
- **Aplicaciones**:
  - Comparación de modelos
  - Selección de hiperparámetros
  - Estimación del error real

Analogía

Como un .^examen simulado"que haces varias veces con diferentes preguntas para prepararte para el examen real.

Validación Simple (Holdout)



- División única entrenamiento/prueba
- Proporción típica 70/30 o 80/20
- Problemas:
  - Alta varianza con datos pequeños
  - Dependencia de la división

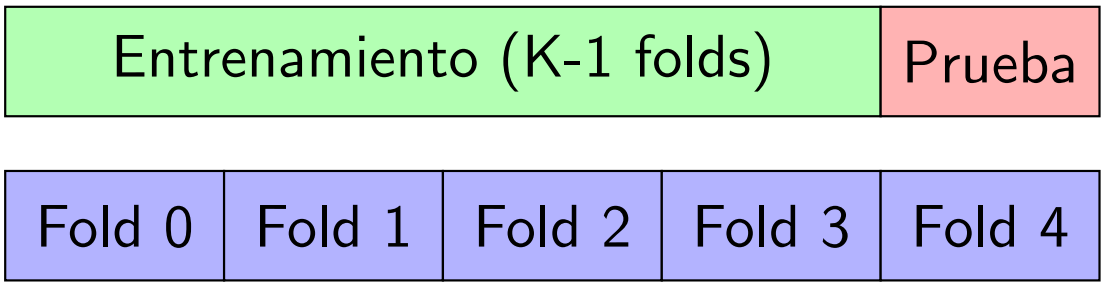
Limitaciones

- No usa todos los datos eficientemente
- Evaluación depende de una sola división

Validación Cruzada K-Fold

Definición

Divide los datos en K subconjuntos (folds) del mismo tamaño, usando K-1 para entrenar y 1 para validar, rotando K veces.



- K iteraciones independientes
- Cada dato en prueba exactamente 1 vez
- Error final: promedio de K evaluaciones

Elección de K

- K=5 o K=10 son valores típicos
- K pequeño: más rápido, más sesgo
- K grande: más lento, menos varianza

Proceso K-Fold Paso a Paso

1. **Mezclar** los datos aleatoriamente
2. **Dividir** en K folds estratificados (manteniendo proporciones de clase)
3. Para cada fold k=1..K:
   - Entrenar modelo con K-1 folds
   - Evaluar con fold k
   - Guardar métrica de rendimiento
4. **Calcular** métrica final como promedio

Estratificación

En problemas de clasificación, mantener proporción de clases en cada fold.

No mezclar antes de dividir

En series temporales, el orden importa (usar TimeSeriesSplit)

Ejemplo Numérico: 5-Fold CV

Cuadro: Rendimiento en cada fold

Fold	MSE	R^2
1	0.45	0.82
2	0.52	0.79
3	0.48	0.81
4	0.50	0.80
5	0.47	0.81
Promedio	0.484	0.806

Interpretación

- El modelo tiene un MSE promedio de 0.48
- La varianza entre folds es baja (estable)
- R^2 consistentemente alrededor de 0.8

Variantes de K-Fold

Leave-One-Out (LOO)

- K = número de muestras
- Entrena con n-1, prueba con 1
- Bajo sesgo, alta varianza
- Costoso computacionalmente

Repeated K-Fold

- Repite K-Fold múltiples veces
- Con diferentes divisiones aleatorias
- Reduce varianza en la estimación

Stratified K-Fold

- Mantiene proporción de clases
- Esencial para datos desbalanceados

Comparación de Métodos de Validación

Cuadro: Características de diferentes métodos

Método	Sesgo	Varianza	Costo
Holdout	Medio	Alto	Bajo
K-Fold (K=5)	Bajo	Medio	Medio
LOO	Muy bajo	Alto	Alto
Repeated K-Fold	Bajo	Bajo	Alto

Recomendaciones

- **Datos grandes**: Holdout o K=5
- **Datos pequeños**: LOO o K=10
- **Clasificación desbalanceada**: Stratified K-Fold
- **Series temporales**: TimeSeriesSplit

Buenas Prácticas en Validación Cruzada

- **Preprocesamiento**: Aplicar dentro de cada fold
  - Scaling, imputación, etc.
  - Evitar data leakage
- **Repetibilidad**: Fijar random state
- **Métricas**: Elegir apropiadas para el problema
- **Hiperparámetros**: Ajustar con CV anidada
- **Visualización**: Graficar resultados por fold

Errores Comunes

- Preprocesar antes de dividir
- No estratificar en datos desbalanceados
- Usar mismo CV para selección de modelo y evaluación final

Introducción a la Extracción de Características

Que ingrresamos a nuestro Algoritmo?

- La **extracción de características** transforma **datos brutos** en **variables predictoras** efectivas
- En regresión lineal, afecta directamente:
  - Capacidad predictiva del modelo
  - Interpretabilidad
  - Cumplimiento de supuestos (linealidad, normalidad, etc.)
- **Objetivos principales:**
  - Capturar patrones relevantes
  - Reducir dimensionalidad
  - Mejorar generalización

Transformaciones Básicas de Características

Operaciones Comunes

- **Escalado**: Normalización, Estandarización
- **Transformaciones no lineales**: log, raíz, cuadrática
- **Discretización**: Binning, categorización
- **Combinaciones**: Interacciones, productos
- **Características polinómicas**: x^2, x^3

Ejemplo: Kernel Polinomico

Para combinar dos características en un kernel polinomia de grado 4:

$$\phi(X) = \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1 x_2 + \theta_5 x_1^3 + \theta_6 x_1^2 x_2 + \theta_7 x_1 x_2^2 + \theta_8 x_2^3 + \theta_9 x_1^4 + \theta_{10} x_1^3 x_2 + \theta_{11} x$$

Características Polinómicas

$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \epsilon \qquad (6)$$

- Captura relaciones no lineales
- Orden determinado por validación cruzada
- Riesgo de sobreajuste

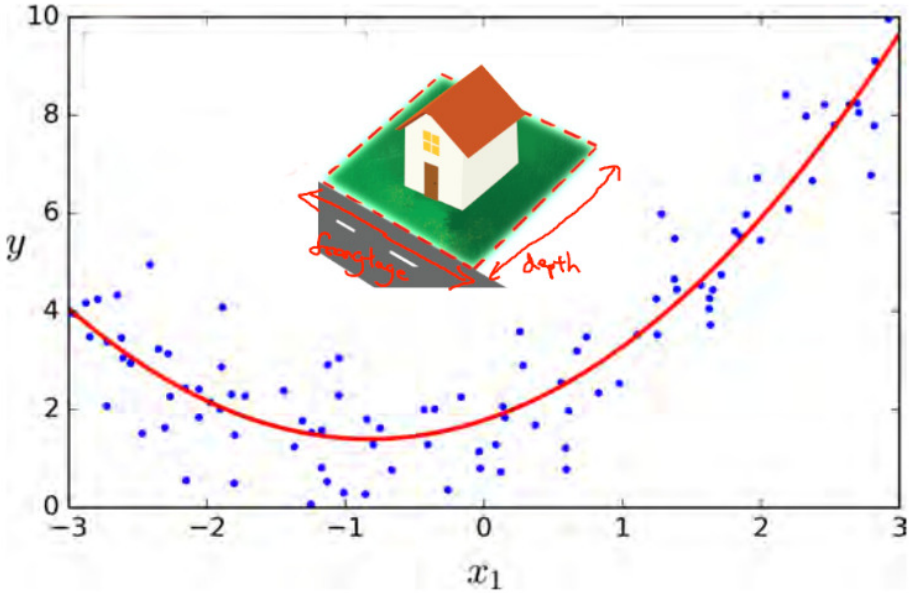


Figura: Regresión polinómica grado 2

Función base No Lineal

- **Modelo lineal básico:**

$$h(\mathbf{x}) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n$$

- **Limitación**: Solo puede modelar relaciones lineales
- **Solución**: Usar combinaciones lineales de funciones base no lineales $\phi(x)$

$$h(\mathbf{x}) = \theta_0 + \sum_{i=1}^{m} \theta_i \phi_i(\mathbf{x})$$

Funciones Base

- Permiten modelar relaciones no lineales manteniendo linealidad en parámetros
- Forma general:

$$h(\mathbf{x}) = \sum_{i=0}^{m} \theta_i \phi_i(\mathbf{x}) = \theta^T \phi(\mathbf{x})$$

- Donde $\phi_0(\mathbf{x}) = 1$ (término de sesgo)

Ejemplos de Funciones Base

- **Polinómicas**: $\phi_j(x) = x^j$
- **Gaussianas**: $\phi_j(x) = e^{\left\{-\frac{(x-\mu_j)^2}{2s^2}\right\}}$
- **Sigmoideas**: $\phi_j(x) = \sigma\left(\frac{x-\mu_j}{s}\right)$

¿Qué son las Funciones Base Polinomiales?

Concepto Central

Transformación de características originales en un **espacio de mayor dimensión mediante términos polinomiales**, permitiendo que modelos lineales capturen **relaciones no lineales.**

- Extienden modelos lineales a relaciones no lineales
- Mantienen la interpretabilidad de regresión lineal
- Requieren cuidado para evitar sobreajuste

$$\phi(x) = [1, x, x^2, x^3, \ldots, x^d]$$

Lógica Matemática de la Transformación

Regresión Lineal Simple:

$$y = \theta_0 + \theta_1 x + \epsilon$$

Regresión Polinomial (Grado d):

$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \cdots + \theta_d x^d + \epsilon$$

Transformación de Características

Creamos nuevas features: $x, x^2, x^3, \ldots, x^d$
El modelo sigue siendo lineal en los parámetros θ_i

Transformación - kernel Polinomial

Antes de la transformación:

$$X = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \end{bmatrix}$$

Después (grado 3):

$$X_{\text{poli}} = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 \\ 1 & x_2 & x_2^2 & x_2^3 \\ 1 & x_3 & x_3^2 & x_3^3 \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}$$

Grados Polinomiales y su Interpretación

Grado 1: Lineal

$$h(x) = \theta_0 + \theta_1 x$$

Grado 2: Cuadrático

$$y = \theta_0 + \theta_1 x + \theta_2 x^2$$

Grado 3: Cúbico

$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$$

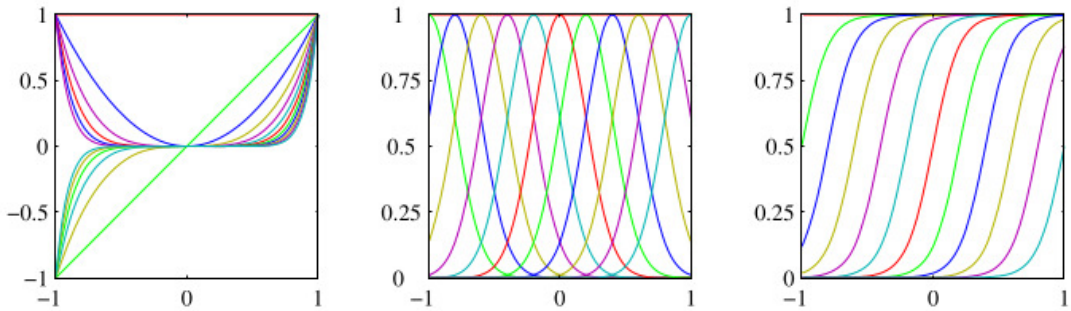


Figura: Ejemplos de funciones de base, mostrando polinomios a la izquierda, gaussianas en el centro y sigmoideas a la derecha.

Ventajas de las Bases Polinomiales

Flexibilidad Controlada

- Captura **relaciones no lineales**
- Mantiene **estructura lineal en parámetros**
- **Fácil** implementación
- **Interpretabilidad** matemática

Aplicaciones Típicas

- Modelado de crecimiento
- Series temporales
- Relaciones físicas no lineales
- Aproximación de funciones complejas

¿Qué son las Funciones Base Radial (RBF)?

Definición

Funciones cuya valor depende únicamente de la distancia desde un punto central (centroide), no de la dirección.

$$\phi(\mathbf{x}) = \phi(\|\mathbf{x} - \mathbf{c}\|)$$

- **Localizadas**: Influencia decrece con la distancia
- **Isotrópicas**: Simétricas en todas direcciones
- **Suaves**: Derivadas de todos los órdenes existen

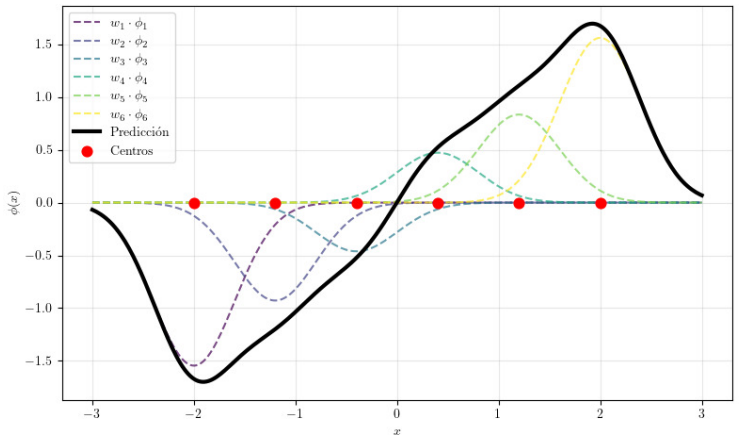
Función Base Gaussiana (RBF Gaussiana)

Forma Matemática

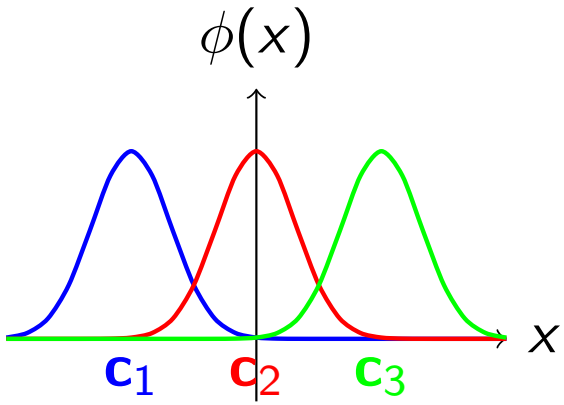
$$\phi(\mathbf{x}, \mathbf{c}) = e^{\left(-\frac{\|\mathbf{x}-\mathbf{c}\|^2}{2\sigma^2}\right)}$$

Parámetros Clave:

- $\mathbf{c}$: Centro de la función
- σ: Ancho (controla suavidad)
- $\|\mathbf{x} - \mathbf{c}\|$: Distancia euclidiana



Interpretación Geométrica



Concepto de Çampo de Influencia"

Cada función Gaussiana actúa como un centro de influencia local

- Máxima influencia en el centro $\mathbf{c}_i$
- Influencia decae exponencialmente con la distancia
- El ancho σ controla el radio de influencia

Implementación en Modelos de Regresión

Modelo con Bases Gaussianas:

$$f(\mathbf{x}) = \theta_0 + \sum_{i=1}^{m} \theta_i \cdot \phi_i(\mathbf{x})$$

$$f(\mathbf{x}) = \theta_0 + \sum_{i=1}^{m} \theta_i \cdot \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}_i\|^2}{2\sigma_i^2}\right)$$

En la Práctica

- Se seleccionan m centros $\mathbf{c}_i$
- Se determina el ancho σ (puede ser único o variable)
- Se optimizan los pesos θ_i por mínimos cuadrados

Selección de Centros y Parámetros

Métodos para Seleccionar Centros:

1. Muestreo aleatorio de datos
2. Distribución uniforme en el espacio
3. Todos los puntos de entrenamiento

Determinación del Ancho σ:

- Regla heurística:

$$\sigma = \frac{d_{\max}}{\sqrt{2M}}$$

- Validación cruzada
- Optimización conjunta con pesos

Consideración Computacional

Con N puntos de datos y M centros: matriz de diseño $N \times M$

Ventajas vs. Bases Polinomiales

Bases Gaussianas:

- ✓Localidad: Influencia controlada
- ✓Suavidad: Derivadas de todos órdenes
- ✓Estabilidad numérica
- ✓Mejor para interpolación

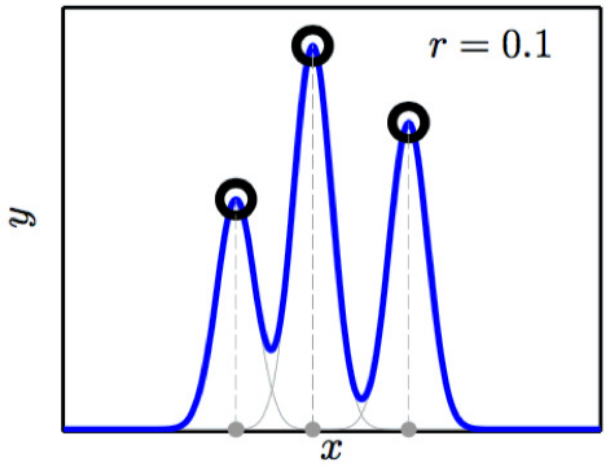
Bases Polinomiales:

- ✓Globalidad: Toda la función afectada
- ✓Interpretabilidad de coeficientes
- ✓Simplicidad computacional
- ✓Mejor para extrapolación

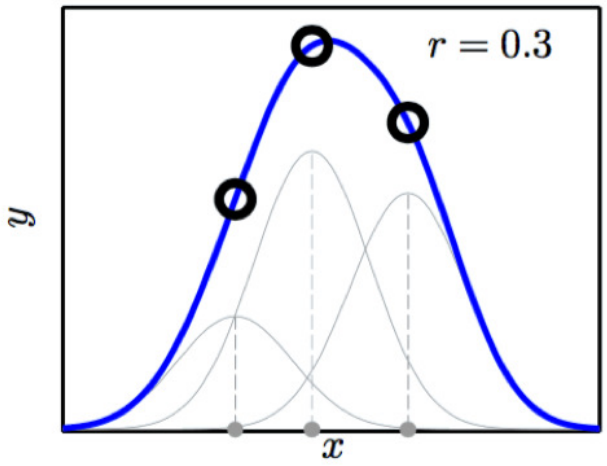
Casos de Uso Típicos

Gaussianas: Aproximación de funciones suaves
Polinomiales: Modelado de tendencias, relaciones físicas

Ejemplo: Aproximación de Función No Lineal



parámetro "r" pequeño



parámetro "r" grande

Función Objetivo:

$$f(x) = \sin(2\pi x) + \text{ruido}$$

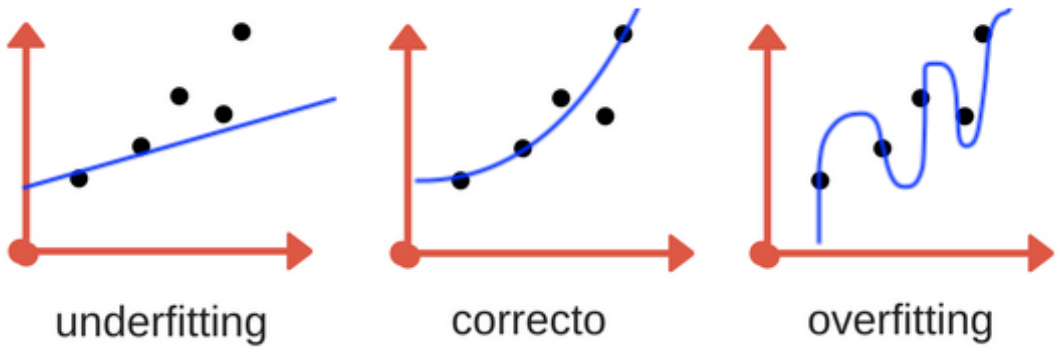
Aproximación con:

- 5 centros Gaussianos
- $\sigma = 0{,}3$
- Mínimos cuadrados

Sobreajuste en Bases Gaussianas

Mecanismos de Sobreajuste:

1. Demasiados centros (uno por punto de datos)
2. Ancho σ muy pequeño (funciones muy "pico")
3. Ausencia de regularización



Consecuencia

El modelo **interpola exactamente** los puntos de entrenamiento, incluyendo el ruido.

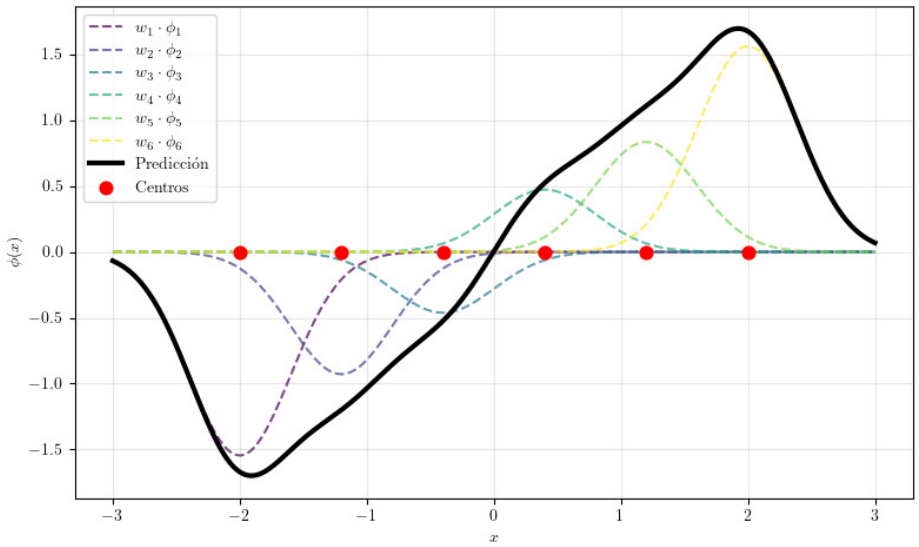
Prevención del Sobreajuste en RBF

Técnicas de Control:

- Regularización Tikhonov:

$$\text{mín } \|h(x) - \Phi\theta\|^2 + \lambda\|\theta\|^2$$

- Selección de centros por validación
- Ancho σ mayor (más suavizado)
- Reducción de centros (menos que puntos datos)



Comparación Directa: Polinomial vs. Gaussiana

Aspecto	Bases Polinomiales	Bases Gaussianas (RBF)
Alcance	Global	Local
Suavidad	Limitada por grado	Infinitamente diferenciable
Estabilidad	Problemas con grados altos	Numéricamente estable
Interpret.	Coeficientes interpretables	Centros interpretables
Overfitting	Control por grado	Control por σ y regulariza
Comp. Cost	$O(d^n)$ con features	$O(N \cdot M)$

Elección Depende de:

- Naturaleza del problema (local vs. global)
- Cantidad y calidad de datos
- Requerimientos de suavidad
- Recursos computacionales

¿Cómo se Produce el Sobreajuste?

El Problema

A medida que combinamos las variables característica, y el número de combinaciones crece, se presenta un problema denominado **"Sobre Ajuste"**

Mecanismos del Sobreajuste:

1. Grado demasiado alto
2. Número insuficiente de datos
3. Ausencia de regularización
4. Ruido en los datos

Consecuencia

El modelo aprende el **ruido** en lugar del **patrón subyacente**

Matemática del Sobreajuste

Complejidad vs. Generalización

- **Grado bajo:** Alto sesgo (underfitting)

  Error alto en entrenamiento y test

- **Grado adecuado:** Balance óptimo

  Error bajo en ambos conjuntos

- **Grado muy alto:** Alta varianza (overfitting)

  Error bajo en entrenamiento, alto en test

Número de parámetros

Para grado d y n datos: riesgo cuando $d \approx n$

Ejemplo Visual: Evolución del Sobreajuste

Grado 1: Muy simple (underfitting)

Grado 3: Balance adecuado

Grado 15: Demasiado complejo (overfitting)

Detección del Sobreajuste

Señales de Alerta

- **Brecha grande** entre error de entrenamiento y test
- Coeficientes β_i con **valores extremos**
- El modelo **no generaliza** a nuevos datos
- Alta sensibilidad a pequeñas variaciones en los datos

Métricas de Diagnóstico

$$\text{Bias}^2 \rightarrow \text{Error por simplificación}$$

$$\text{Variance} \rightarrow \text{Error por sensibilidad al ruido}$$

$$\text{MSE}_{\text{train}} \ll \text{MSE}_{\text{test}} \Rightarrow \text{Overfitting}$$

Prevención y Soluciones al Sobreajuste

Técnicas de Prevención:

- Validación cruzada para seleccionar grado
- Regularización (Ridge, Lasso)
- Early stopping
- Aumentar tamaño del dataset

En la práctica:

- Comenzar con grados bajos (2-4)
- Usar `learning curves`
- Regularización automática
- Ensemble methods

Regla Empírica

"Prefiera modelos simples que expliquen bien los datos, en lugar de modelos complejos que los memoricen"

Mínimos Cuadrados Regularizados

- Para controlar el sobreajuste, añadimos un término de regularización:

$$J(\theta) = J_D(\theta) + \lambda J_W(\theta)$$

- Regularizador cuadrático (**weight decay**):

$$J_W(\theta) = \frac{1}{2}\theta^T\theta$$

- Función de error total:

$$J(\theta) = \frac{1}{2}\sum_{i=1}^{m}\{\theta^T\phi(\mathbf{x}^{(i)}) - y^{(i)}\}^2 + \frac{\lambda}{2}\theta^T\theta$$

Solución Regularizada

- La solución de mínimos cuadrados regularizada:

$$\theta = (\lambda \mathbf{I} + \mathbf{\Phi}^T \mathbf{\Phi})^{-1} \mathbf{\Phi}^T \mathbf{y}$$

- Esta es una extensión simple de la solución no regularizada

Regularizadores Generalizados

$$J(\theta) = \frac{1}{2} \sum_{i=1}^{m} \{t_n - \theta^T \phi(\mathbf{x^{(i)}})\}^2 + \frac{\lambda}{2} \sum_{j=1}^{n} |\theta_j|^q$$

- $q = 2$: Ridge regression (cuadrático)
- $q = 1$: Lasso (produce modelos dispersos)

Descomposició n Sesgo-Varianza

- El error esperado se puede descomponer en tres partes:

$$\mathbb{J}[L] = (\text{sesgo})^2 + \text{varianza} + \text{ruido}$$

- **Sesgo**: Error debido a suposiciones incorrectas del modelo
- **Varianza**: Sensibilidad a pequeñas variaciones en los datos de entrenamiento
- **Ruido**: Irreducible, debido a la naturaleza intrínseca de los datos

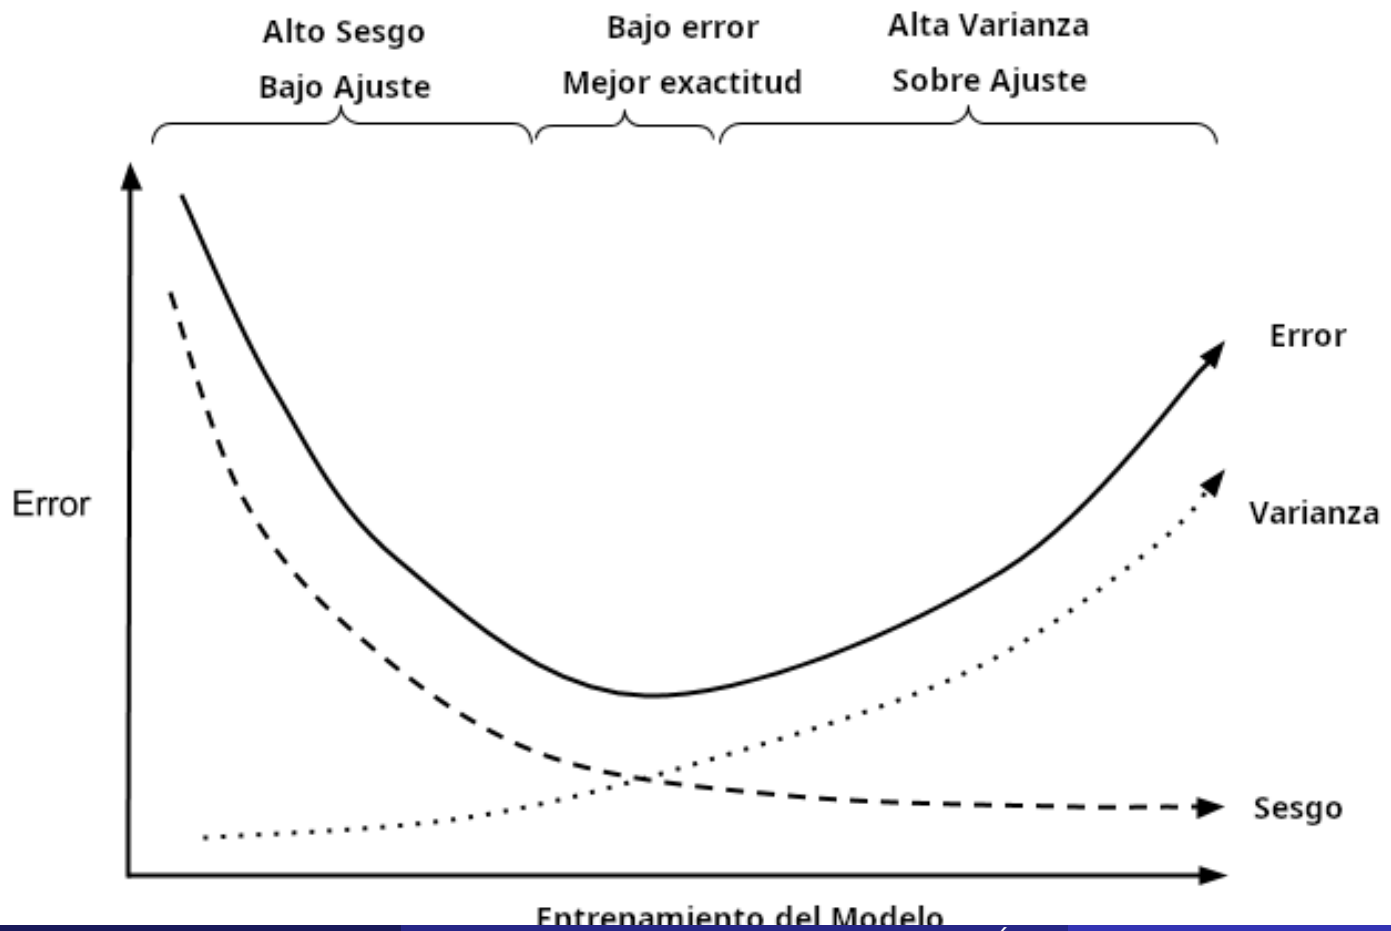
Expresiones Formales

$$(\text{sesgo})^2 = \int \{\mathbb{J}_{\mathcal{D}}[y(\mathbf{x};\mathcal{D})] - h(\mathbf{x})\}^2 p(\mathbf{x}) d\mathbf{x}$$

$$\text{varianza} = \int \mathbb{J}_{\mathcal{D}}[\{y(\mathbf{x};\mathcal{D}) - \mathbb{J}_{\mathcal{D}}[y(\mathbf{x};\mathcal{D})]\}^2] p(\mathbf{x}) d\mathbf{x}$$

Compensación Sesgo-Varianza

- **Sobre Ajuste**: bajo sesgo, alta varianza
- **Bajo Ajuste:** alto sesgo, baja varianza
- El modelo óptimo encuentra el balance entre ambos



Buenas Prácticas en Extracción de Características

- **Validación cruzada**: Procesamiento dentro de cada fold
- **Interpretabilidad**: Balance entre rendimiento y explicabilidad
- **Escalabilidad**: Considerar costo computacional
- **Dominio del problema**: Incorporar conocimiento experto
- **Visualización**: Explorar relaciones antes de modelar

Errores Comunes

- Fuga de datos (data leakage)
- Sobreingeniería de características
- Ignorar relaciones no lineales
- Tratar coordenadas como variables independientes

¿Por qué Seleccionar Características?

- **Problema**: Demasiadas variables predictoras pueden:
  - Reducir interpretabilidad
  - Aumentar sobreajuste
  - Incluir redundancias
  - Disminuir rendimiento computacional
- **Solución**: Técnicas de selección para:
  - Identificar variables más relevantes
  - Eliminar redundancias
  - Optimizar capacidad predictiva

Objetivos clave

- Mejorar generalización
- Reducir complejidad
- Mantener/maximizar poder predictivo

Tipos de Métodos de Selección

Métodos Filtro

- Selección pre-modelado
- Basados en estadísticos
- Ejemplos:
  - Correlación
  - χ^2
  - ANOVA

Tipos de Métodos de Selección

Métodos Wrapper

- Usan el modelo como caja negra
- Buscan combinaciones óptimas
- Ejemplos:
  - Forward/Backward
  - Eliminación recursiva

Tipos de Métodos de Selección

Embedded

- Selección durante modelado
- Ejemplos:
  - Lasso
  - Ridge

Métodos Filtro: Ejemplo con Correlación

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} \tag{7}$$

Cuadro: Correlación con Precio (Ejemplo)

Característica	Correlación
metros_cuadrados	0.82
num_habitaciones	0.65
distancia_centro	-0.58
año_construccion	0.42

Métodos Wrapper

Forward Selection

1. Comenzar sin variables
2. Añadir una a una la que mejora más el modelo
3. Parar cuando no hay mejora significativa

Consideraciones

- Costoso computacionalmente
- Riesgo de sobreajuste

Métodos Embedded: Regularización Lasso

Regularización

$$\min_{\theta} \left(\frac{1}{2m} \sum_{i=1}^{m} (X\theta - y)^2 + \frac{\lambda}{2m} \sum_{j=1}^{n} |\theta_j^2| \right) \tag{8}$$

- λ controla fuerza de regularización
- Penalización L1 tiende a producir coeficientes exactamente cero
- Efecto de selección automática

Evaluación de Métodos

Cuadro: Comparación de Técnicas

Método	Ventajas	Desventajas	Caso de Uso
Filtro	Rápido	Ignora interacciones	Pre-procesamiento
Wrapper	Óptimo	Costoso	Pequeños datasets
Embedded	Balance	Específico de modelo	Regularización

Métricas de Evaluación

- Error de validación cruzada
- R^2 ajustado
- AIC/BIC
- Parsimonia vs. rendimiento

Buenas Prácticas en Selección

- **Validación cruzada**: Realizar selección dentro de cada fold
- **Dominio del problema**: Incorporar conocimiento experto
- **Iterativo**: Probar múltiples enfoques
- **Estabilidad**: Verificar consistencia en submuestras
- **Interpretabilidad**: Priorizar modelos comprensibles

Errores Comunes

- Data leakage (filtración de datos)
- Sobreoptimización en métricas
- Ignorar interacciones relevantes
- Eliminar variables por correlación alta sin análisis